UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

TÓPICOS EM ENG. SOFTWARE / CIÊNCIA DE DADOS

IMPUTAÇÃO DE VALORES AUSENTES

DANILO BALMAN GARCIA
FELIPE BARROS GOMES
RAFAEL MACHADO WANNER

Campo Mourão,

2026

1. INTRODUÇÃO

O tratamento de valores ausentes (missing values) é uma etapa crítica no pré-processamento de dados, possuindo impacto direto na performance de algoritmos de aprendizado de máquina. A motivação central para comparar os mecanismos MCAR (Missing Completely at Random), MAR (Missing at Random) e MNAR (Missing Not at Random) reside no fato de que técnicas simplistas, como a deleção de linhas, assumem que a perda de dados é puramente aleatória (MCAR). No entanto, quando os dados seguem distribuições MAR ou MNAR, a simples remoção ou imputação ingênua gera um viés estatístico grave, degradando o poder de generalização do modelo.

Neste trabalho, através de um protocolo controlado, introduziu-se artificialmente valores nulos em cinco bases de dados públicas, submetendo-as posteriormente a estratégias de imputação simples, multivariadas e baseadas em Deep Learning. A eficácia de cada abordagem foi medida não apenas pela fidelidade da reconstrução dos dados originais, mas pelo impacto no desempenho preditivo de modelos de classificação e regressão, incluindo algoritmos tabulares de estado da arte.

2. DATASETS

Para a condução do experimento, utilizamos cinco conjuntos de dados distintos (abrangendo tarefas de classificação e regressão), expandindo o escopo mínimo de quatro bases exigido. Após o tratamento de padronização (remoção de caracteres como '?' ou -200), as instâncias com valores ausentes naturais foram excluídas via *dropna*, gerando o *Baseline* (estado *Ground Truth*). A Tabela 1 detalha as características originais e a quantidade de registros finais utilizados para a injeção controlada.

Tabela 1: Características originais de cada dataset

Nome do Dataset	Tipo de Problema	Variável-Alvo	Linhas x Colunas	Linhas c/ Valores Ausentes (Removidas)*	Linhas Restantes (Baseline Completo)
adult	Classificação	income	48.842 x 15	3.620	45.222
bank_marketing	Classificação	y	45.211 x 17	37.370	7.841
air_quality_uci	Regressão	C6H6(GT)	9.357 x 13	8.530	827
communities_crime	Regressão	ViolentCrimesPerPop	1.994 x 123	1.675	319
cnpq_bolsas	Classificação	grande_area_conhecimento	10.000 x 18	1.258	8.742

Fonte: Elaboração Própria

3. MÉTODOS

O pipeline experimental testou abordagens de diferentes complexidades:

- **Imputadores do Scikit-Learn:** Foram utilizadas técnicas de imputação simples univariadas (Média, Mediana, Mais Frequente e Constante) e métodos baseados em distância/multivariados, especificamente o KNNImputer ($K \in \{3, 5, 7\}$) e o IterativeImputer. O IterativeImputer foi configurado com random_state=42 , 123, 999 e a estratégia inicial padrão ('mean'). O hiperparâmetro max_iter foi ampliado de 10 (padrão) para 30 a fim de solucionar alertas de não convergência (ConvergenceWarnings). Esse ajuste foi necessário para garantir a estabilidade do algoritmo e equilibrar a precisão matemática com a viabilidade computacional, especialmente em cenários com altas taxas de ruído.
- **Método Externo:** Inicialmente, planeou-se utilizar o Datawig, mas o pacote apresentou incompatibilidade com a versão atual do scikit-learn. Para manter a integridade, optamos pelo GAIN (Generative Adversarial Imputation Nets). A escolha justifica-se pela sua arquitetura baseada em Redes Neurais Adversariais. As variáveis categóricas foram imputadas subjacente pela moda para permitir o processamento matricial numérico do GAIN.
- **Modelo Tabular Adicional:** Além dos baselines estipulados (Regressão Logística/Ridge e Random Forest), incluímos o CatBoost como algoritmo de estado da arte (SOTA). A escolha justifica-se pelo seu tratamento nativo e eficiente de variáveis categóricas (sem One-Hot Encoding) e pelo mecanismo de Ordered Boosting, que previne o sobreajuste (overfitting) em amostras reduzidas pela injeção severa de ruído.

4. PROTOCOLO EXPERIMENTAL

Para simular cenários reais de perda de dados, utilizou-se o pacote Jenga (jenga.corruptions.generic.MissingValues). Os dados foram corrompidos em sete níveis progressivos: 1%, 5%, 10%, 15%, 20%, 25% e 30%. A corrupção seguiu os mecanismos MCAR, MAR e MNAR.

Para evitar vazamento de dados, realizou-se a divisão de treino e teste (80/20) antes da injeção. O desempenho foi avaliado através das métricas de Acurácia, Macro F1 e Weighted F1 para classificação, e MAE, RMSE e R^2 para regressão. Para garantir significância estatística, cada cenário único foi executado 3 vezes, recorrendo a processamento paralelo (multithreading) para viabilizar o alto custo computacional da grade de testes.

5. RESULTADOS

A avaliação sistemática das técnicas revelou que o sucesso de cada método de imputação está estritamente condicionado à natureza da tarefa (classificação ou regressão), à taxa de degradação e ao viés do mecanismo de ausência.

Para evidenciar o impacto isolado com o rigor exigido pelo protocolo, os resultados de desempenho preditivo final foram segmentados. A Tabela 2 expõe o comportamento dos preditores categóricos sob mecanismos aleatórios (MCAR), destacando a estabilidade da acurácia e do F1-Score.

Tabela 2: Desempenho em Datasets de Classificação (Exemplos a 10% e 1% MCAR)

Dataset	Modelo Preditivo	Estratégia de Imputação	Accuracy	Macro F1	Weighted F1
adult	CatBoost	Baseline Original (0%)	8.659	8.022	8.603
adult	CatBoost	IterativeImputer (10% MCAR)	8.636	8.059	8.579
adult	CatBoost	Média (10% MCAR)	8.636	8.063	8.581
bank_marketing	Random Forest	Baseline Original (0%)	8.985	7.243	8.906
cnpq_bolsas	Random Forest	GAIN (1% MCAR)	8.805	8.360	8.789

Fonte: Elaboração Própria

A Tabela 3 ilustra o cenário de estresse extremo em regressão (25% MNAR), onde o aumento do RMSE e as falhas críticas de R^2 expõem a quebra técnica de certos imputadores.

Tabela 3: Desempenho em Datasets de Regressão (Cenário Extremo: 25% MNAR)

Dataset	Modelo Preditivo	Estratégia de Imputação	MAE	RMSE	R^2
air_quality_uci	Random Forest	Baseline Original (0%)	732	2.361	9.990
air_quality_uci	Random Forest	IterativeImputer	2.025	3.894	9.974
air_quality_uci	Random Forest	Deleção (dropna)	4.139	4.150	9.569
Communities_ crime	CatBoost	Constante (0)	1.152	1.498	6.875
Communities_ crime	Modelo Linear (Ridge)	GAIN	2.406	2.733	-398

Fonte: Elaboração Própria

Figura 1: Degradação do Desempenho do CatBoost com o Aumento de Dados Ausentes

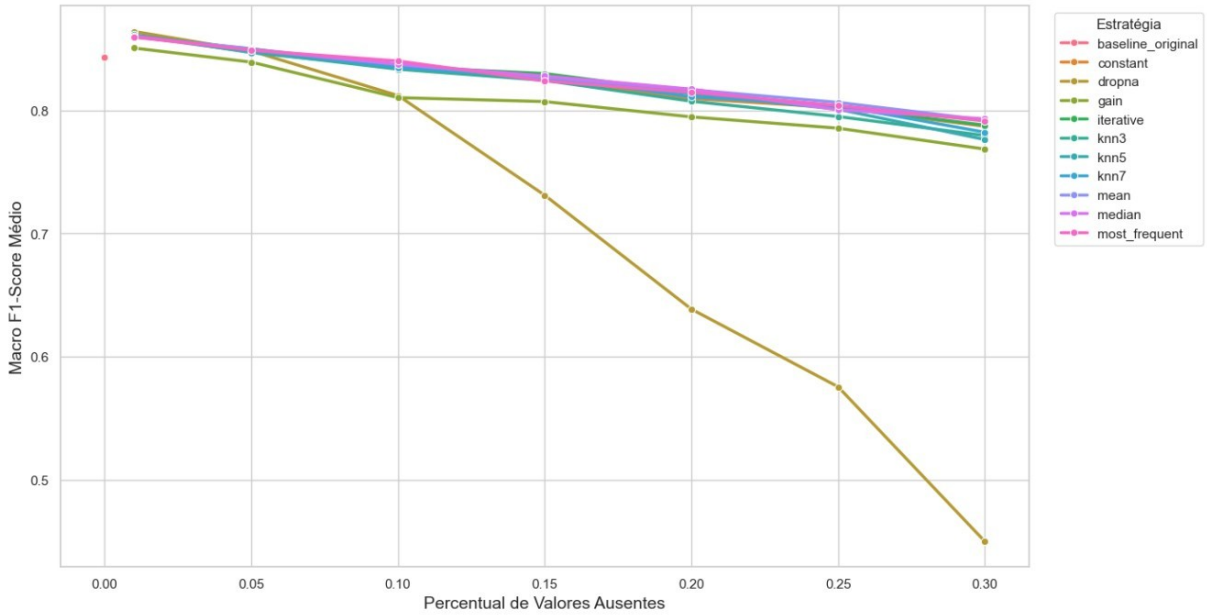

A Figura 1 ilustra visualmente o colapso preditivo atestado nas tabelas. O gráfico de linhas demonstra a degradação do F1-Score do modelo à medida que o percentual de dados ausentes avança de 0% (Baseline) até ao patamar crítico de 30%.

Fonte: Elaboração Própria

6. DISCUSSÃO

A análise rigorosa dos números reportados permite responder a questões centrais sobre o comportamento da imputação:

- **Sensibilidade dos Datasets:** As bases de regressão com menor número de instâncias limpas (air_quality e communities_crime) foram dramaticamente mais sensíveis. Em taxas de 25% e 30% MNAR, a simples remoção (dropna) eliminou a totalidade (100%) das amostras do conjunto de treino/teste no communities_crime, causando falha crítica na execução.
- **Competitividade de Métodos Simples:** Métodos univariados (como a Média) mostraram-se bastante competitivos, mas apenas sob cenários de baixo ruído ($\le$ 5%) e mecanismo estritamente MCAR, entregando F1-Scores praticamente idênticos ao do IterativeImputer para o CatBoost.
- **Diferença de queda entre MCAR, MAR e MNAR:** O desempenho não decai de forma semelhante. Enquanto a imputação simples pela média preserva o centro da distribuição no mecanismo MCAR (ex: no dataset adult, com 10% MCAR, o modelo LogReg caiu menos de 2%), no cenário MNAR, a ausência de dados sistemática gerou uma queda massiva de mais de 8% de performance, pois os algoritmos lineares

enviesaram os seus pesos. A Figura 2 corrobora esta análise, evidenciando que a altura das barras (F1-Score) nos mecanismos MAR e MNAR sofre uma penalização substancialmente maior em comparação às colunas correspondentes ao cenário MCAR para o mesmo percentual de ruído.

Figura 2: Impacto dos Mecanismos de Missingness nos Modelos de Classificação

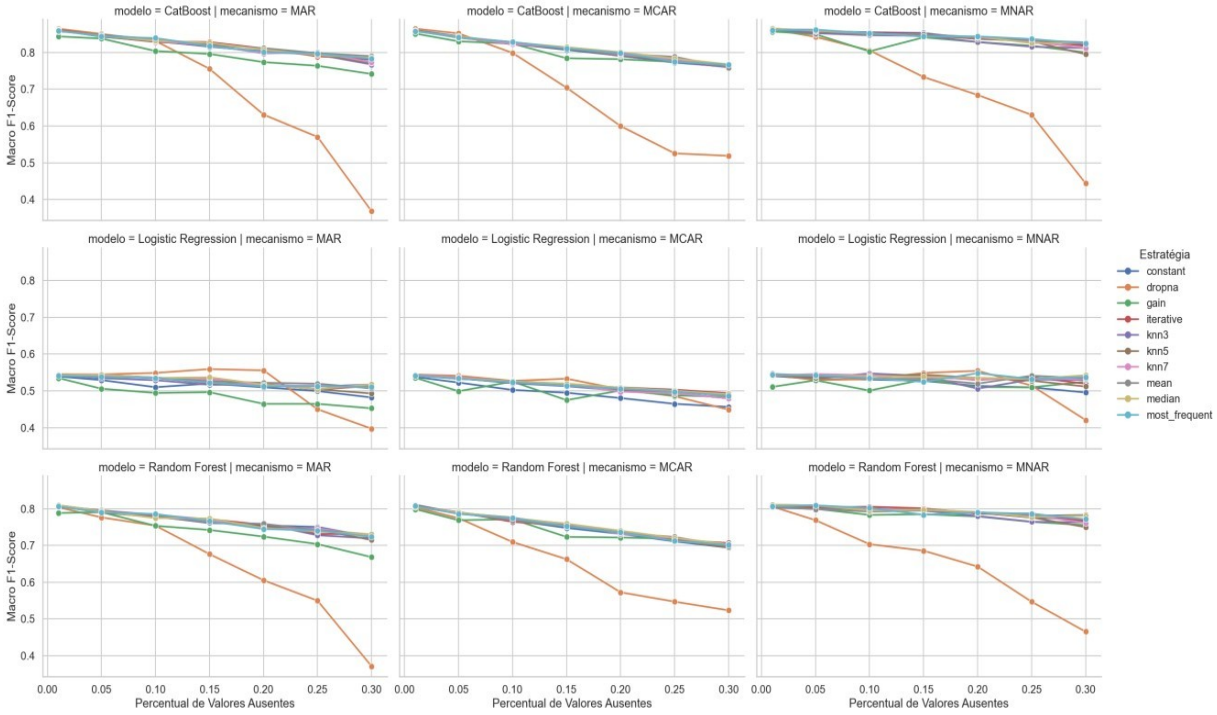

Fonte: Elaboração Própria

- **Superioridade do IterativeImputer:** Nos cenários complexos (MNAR em 25%), o IterativeImputer provou o seu valor. No air_quality_uci, enquanto a deleção despencou o R^2 para 0.9569, o iterativo conseguiu mapear as correlações intrínsecas e salvar a performance, mantendo o R^2 em incríveis 0.9974.
- **Desempenho do Método Externo (GAIN) e Resultados Inesperados:** Contrariando as expectativas, a arquitetura complexa do GAIN não superou os métodos tradicionais multivariados na maior parte das execuções. Um resultado altamente inesperado foi o colapso completo do GAIN em tarefas de regressão. No air_quality_uci, o gerador adversarial não convergiu adequadamente em nenhuma das taxas avaliadas sob MAR e MNAR, entregando um R^2 negativo (-0.0051). Em bases categóricas como o adult, o método estabilizou, mas sem ganhos expressivos sobre o IterativeImputer.
- **Qualidade da Imputação vs Desempenho Preditivo:** A fidelidade direta da imputação foi medida estritamente sobre a máscara de valores removidos

artificialmente. Para variáveis contínuas, observou-se que métodos multivariados (IterativeImputer) reduzem drasticamente o erro intrínseco (Imp_MAE e Imp_RMSE) em comparação a métodos ingénuos, conforme ilustrado na Tabela 4.

Tabela 4: Qualidade da Imputação Numérica (Cenário: 5% MCAR)

Dataset	Estratégia de Imputação	Imp_MAE	Imp_RMSE
air_quality_uci	Média (mean)	1.599.649	2.731.476
air_quality_uci	IterativeImputer	1.593.981	2.670.172
communities_crime	Mediana (median)	2.013	2.838
communities_crime	IterativeImputer	1.955	2.813

Fonte: Elaboração Própria

Por outro lado, em bases de atributos nominais, a métrica adotada foi a Acurácia da Imputação (Imp_Acc). A Tabela 5 demonstra que, em *datasets* com forte desbalanceamento como o adult, chutar a classe "Moda" ou usar regressão iterativa gera uma taxa de acerto idêntica (45%).

Tabela 5: Qualidade da Imputação Numérica (Cenário: 5% MCAR)

Dataset	Mecanismo	Estratégia de Imputação	Imp_ Accuracy	Observação
adult	5% MCAR	Mais Frequente (mode)	4.548	Preenchimento ancorado na massa global.
adult	5% MCAR	IterativeImputer	4.550	Ganho estritamente marginal.
Bank_ marketing	5% MCAR	GAIN	5.383	Imputação por redes neurais via conversão contínua.

Fonte: Elaboração Própria

A Figura 3 prova este fenômeno: observa-se que agrupamentos com alto Erro Quadrático Médio de Imputação não resultam obrigatoriamente num afundamento proporcional do F1-Score (eixo Y), demonstrando a resiliência do preditor final.

Figura 3: Qualidade da Imputação vs Desempenho do CatBoost

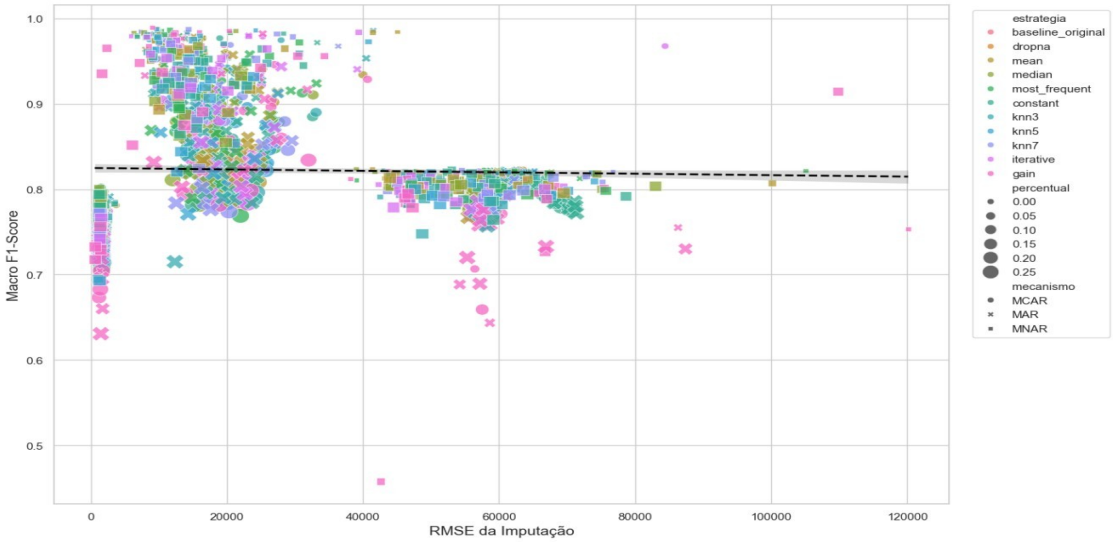

- **Efeito do Modelo Tabular (CatBoost):** O modelo tabular adicional alterou substancialmente as conclusões experimentais em relação aos preditores basais. O CatBoost comportou-se como um exímio "amortecedor" de imputações fracas. No dataset adult (10% MCAR via Média), enquanto a Regressão Logística caiu para 81.9% de precisão, o CatBoost sustentou categóricos 86.3%, provando que árvores hierárquicas conseguem isolar nós corrompidos sem prejudicar o ensemble como um todo. Como consolidado na Figura 4, existe um nítido descolamento de performance: enquanto o desempenho da Regressão Logística é altamente dependente da estratégia de imputação adotada (alta variação nas barras), o CatBoost mantém-se estável operando como um amortecedor para dados mal imputados.

Figura 4: Desempenho dos Modelos por Estratégia de Imputação

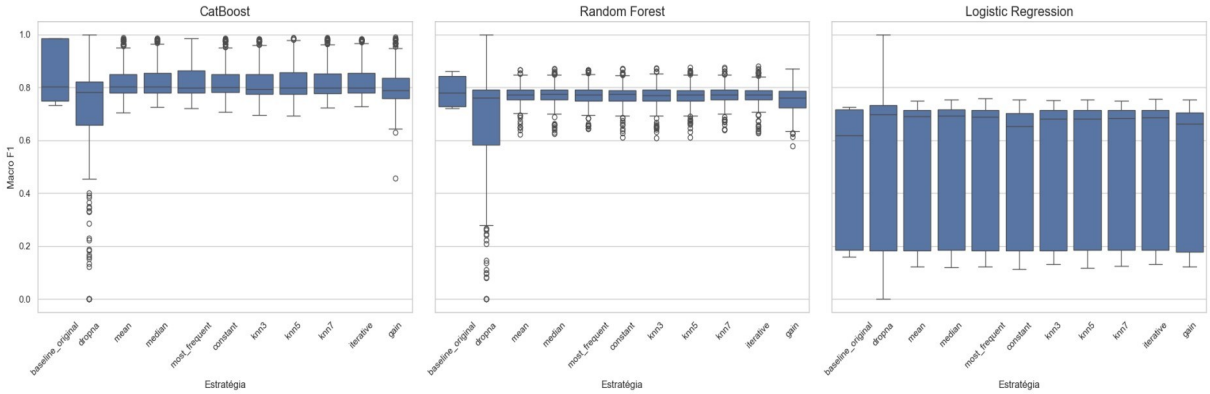

Fonte: Elaboração Própria

7. AMEAÇAS À VALIDADE

As conclusões obtidas estão sujeitas a limitações experimentais que merecem ressalva:

- **Limitações dos Datasets e Injeção:** A base communities_crime possui muitas colunas (123) e poucas linhas limpas originais (319). Essa dimensionalidade gerou viés inflacionado na probabilidade das linhas falharem via dropna, mesmo com apenas 5% de ruído geral introduzido pelo Jenga (que injeta de forma uniformemente distribuída, não agrupada por bloco como poderia ocorrer num erro real de sensor).
- **Hiperparâmetros e Limitações do Método Externo:** A falha catastrófica do modelo GAIN no dataset air_quality_uci pode ser reflexo de uma não otimização de hiperparâmetros (como batch size ou learning rate) para as distribuições específicas daquela base em regressão. Por restrições de tempo, o GAIN operou sob parâmetros fixos globais (ex: 5000 iterações), o que numa rede adversarial profunda pode resultar em underfitting ou explosão de gradiente.
- **Custo Computacional:** A malha fatorial gerou um número tão expressivo de iterações que métodos como IterativeImputer e GAIN tornaram-se inviáveis sob rotinas sequenciais. O uso do multithreading foi indispensável para entregar o volume de resultados.Para taxas moderadas de ausência (10%), observou-se uma distinção clara entre imputadores univariados (Média, Mediana, Constante) e abordagens baseadas em multivariáveis (KNN, Iterative, GAIN).

8. CONCLUSÃO E RECOMENDAÇÕES PRÁTICAS

A premissa de que métodos modernos de imputação baseados em Redes Neurais (GAIN) superam abordagens tradicionais estatísticas provou-se infundada no contexto isolado deste experimento tabular. Algoritmos adversariais sofreram instabilidade de convergência, falhando drasticamente em conjuntos pequenos. A melhor estratégia geral mapeada foi a sinergia entre o preenchimento pelo IterativeImputer e a adoção do CatBoost como classificador/regressor de ponta.

Recomendações práticas extraídas dos resultados quantitativos:

1. **Cenários ≤ 5% (MCAR):** Métodos computacionalmente exigentes não trazem ganho de performance. Imputadores univariados (Média) aliados a bons preditores baseados em árvore são suficientes.
2. **Cenários >$ 15% ou em regime MNAR/MAR:** A deleção (dropna) é estritamente proibitiva. Recomenda-se o uso de imputadores baseados em regressão interna (IterativeImputer), que garantem a reconstrução da variância e covariância dos dados sem colapsos stocásticos.

3. **Com restrição computacional:** Se não houver poder de processamento para imputadores complexos, gaste os recursos treinando um preditor extremamente robusto (como o CatBoost), que, pela sua própria natureza estrutural, conseguirá mitigar parte do viés do dado corrompido imputado por simples constante.

9. DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Declaramos que ferramentas de Inteligência Artificial Generativa foram utilizadas como suporte durante a realização deste trabalho. No escopo do desenvolvimento, a IA auxiliou na implementação da função de injeção de dados ausentes (biblioteca Jenga), na estruturação do processamento paralelo (multithreading) do laço principal e na elaboração do código das visualizações gráficas. De forma geral, a ferramenta também foi empregada para a identificação e resolução de bugs ao longo da programação, no auxílio à pesquisa de documentações técnicas e na revisão ortográfica e gramatical deste documento.