UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

Câmpus Campo Mourão

Aluno(a)			**RA**:
Curso		**Ano:**	
Disciplina	Tópicos em Eng. Software - Ciência de Dados		
Professor	Prof. Eduardo Pena		
Nota			
Trabalho: Imputação de Valores Ausentes			

Orientações gerais:

1 - Todos os materiais (códigos fontes, documentos, diagramas, etc) deverão ser entregues em um arquivo .zip identificado (Nome/RA/Ano).

2 - A interpretação das questões é parte do processo de avaliação.

Formato: Grupos de até 2 alunos

Apresentação individual: Aproximadamente 2 minutos por aluno

Entrega: Relatório (PDF) + Notebook Jupyter (.ipynb) + Arquivos de resultados + README de reprodução

Objetivo

O objetivo deste trabalho é avaliar, de forma experimental, como diferentes técnicas de imputação se comportam sob diferentes mecanismos e níveis de valores ausentes.

O grupo deve construir um protocolo controlado de injeção de valores ausentes, executar diferentes técnicas de imputação e analisar o impacto dessas escolhas no desempenho de modelos preditivos.

O notebook inicial fornecido já contém o carregamento dos datasets, a normalização de valores ausentes, o baseline com `dropna`, os modelos básicos e a geração inicial de resultados. A partir dele, o grupo deve implementar a injeção controlada de nulos e ampliar os experimentos.

Datasets

Cada grupo deve executar os experimentos para os **quatro datasets** disponíveis no notebook inicial:

- `adult`;
- `bank_marketing`;
- `air_quality_uci`;
- `communities_crime`.

O relatório deve incluir uma tabela-resumo dos quatro datasets, contendo:

- nome do dataset;
- tipo de problema: classificação ou regressão;
- variável-alvo;
- número de linhas e colunas;
- quantidade original de valores ausentes;
- quantidade de linhas restantes após a criação da versão completa usada no experimento controlado.

Protocolo Experimental

O grupo deve partir de uma versão completa dos dados, isto é, sem valores ausentes nos atributos de entrada e sem valores ausentes na variável-alvo. Essa versão será usada como referência para a injeção controlada de valores ausentes.

Para cada dataset, o protocolo deve seguir a ordem abaixo:

1. carregar o dataset;
2. normalizar os marcadores de valores ausentes;
3. criar uma versão completa do dataset, removendo linhas com nulos;
4. separar atributos de entrada e variável-alvo;
5. injetar valores ausentes artificialmente nos atributos de entrada;
6. separar treino e teste;
7. ajustar o imputador apenas no treino;
8. aplicar o imputador no treino e no teste;
9. treinar os modelos;
10. avaliar os resultados no teste.

A variável-alvo não deve receber valores ausentes artificiais.

Injeção de Valores Ausentes

A injeção de valores ausentes deve ser feita usando a ferramenta `Jenga`:

`https://github.com/schelterlabs/jenga`

O grupo deve injetar valores ausentes considerando os seguintes mecanismos:

- **MCAR**: valores ausentes completamente ao acaso;
- **MAR**: valores ausentes dependentes de outros atributos observados;
- **MNAR**: valores ausentes dependentes do próprio valor que será removido.

Para cada mecanismo, devem ser avaliados os seguintes percentuais de valores ausentes:

`1%, 5%, 10%, 15%, 20%, 25%, 30%`

Assim, para cada dataset, o grupo terá pelo menos:

$$\texttt{3 mecanismos} \times \texttt{7 percentuais} = \texttt{21 cenários de valores ausentes}$$

Técnicas de Imputação

A documentação dos imputadores do `scikit-learn` está disponível em:

`https://scikit-learn.org/stable/modules/impute.html`

O grupo deve comparar métodos básicos, métodos intermediários e métodos mais robustos.

1. Baseline com `dropna`

O resultado com `dropna` do notebook inicial deve ser mantido como baseline. No experimento com nulos injetados, o grupo também deve registrar o que acontece quando as linhas com nulos artificiais são removidas.

2. Imputadores do `scikit-learn`

O grupo deve incluir os seguintes métodos:

- `SimpleImputer` com `mean`;
- `SimpleImputer` com `median`;
- `SimpleImputer` com `most_frequent`;
- `SimpleImputer` com `constant`;
- `KNNImputer`;
- `IterativeImputer`.

Para o `KNNImputer`, o grupo deve testar vários valores de $n_neighbors$.

Para o `IterativeImputer`, o grupo deve informar a configuração utilizada e justificar as principais escolhas, como `max_iter`, `initial_strategy`, estimador interno e `random_state`.

3. Métodos externos ao `scikit-learn`

Além dos métodos do `scikit-learn`, o grupo deve executar pelo menos **um método de imputação mais robusto**, de fora do `scikit-learn`.

Os métodos podem ser escolhidos entre os exemplos abaixo ou outros métodos recentes, desde que o grupo justifique a escolha.

- GAIN: Generative Adversarial Imputation Nets.
- Datawig.
- Retrieval-Augmented Imputation.
- DiffPuter.
- métodos baseados em diffusion models ou diffusion transformers.

Sugestões de referências e implementações:

- **GAIN**: `https://github.com/jsyoon0823/GAIN`
  `https://proceedings.mlr.press/v80/yoon18a/yoon18a.pdf`
- **Datawig**: `https://github.com/kennethleungty/DataWig-Missing-Data-Imputation`
  `https://jmlr.org/papers/v20/18-753.html`

- **Retrieval-Augmented Imputation**: `https://dl.acm.org/doi/pdf/10.14778/3748191.3748200`

  `https://github.com/HKUSTDial/Retrieval_Augmented_Imputation`

Referências adicionais que podem ser usadas na implementação:

- Hengrui Zhang, Liancheng Fang, Qitian Wu, Philip S. Yu. *DiffPuter: Empowering Diffusion Models for Missing Data Imputation*. ICLR 2025.
- Diju Liu, Yalin Wang, Chenliang Liu, Xiaofeng Yuan, Kai Wang, Chunhua Yang. *Scope-Free Global Multi-Condition-Aware Industrial Missing Data Imputation Framework via Diffusion Transformer*. IEEE TKDE 36(11): 6977–6988, 2024.
- Sitao Min, Hafiz Salman Asif, Xinyue Wang, Jaideep Vaidya. *Cafe: Improved Federated Data Imputation by Leveraging Missing Data Heterogeneity*. IEEE TKDE 37(5): 2266–2281, 2025.

Caso algum método externo não rode em todos os datasets por limitação computacional ou incompatibilidade de tipos de dados, o grupo deve documentar claramente o problema e propor uma solução razoável, como amostragem, seleção de colunas ou execução em subconjunto. **Não basta apenas remover o método da comparação.**

Modelos Preditivos

Os modelos do notebook inicial devem ser mantidos:

Para classificação:

- Regressão Logística;
- Random Forest Classifier.

Para regressão:

- Ridge Regression;
- Random Forest Regressor.

Além desses, o grupo deve incluir pelo menos **um modelo de estado da arte para dados tabulares**.

O grupo deve escolher pelo menos um entre:

- **CatBoost**;
- **LightGBM**;
- **XGBoost**;
- **TabPFN** ou **TabPFN-2.5**.

O relatório deve justificar a escolha do modelo adicional. Por exemplo, CatBoost é uma opção forte quando há atributos categóricos; LightGBM é uma opção eficiente para datasets maiores; XGBoost é um baseline consolidado em dados tabulares; TabPFN e TabPFN-2.5 são opções recentes baseadas em modelos fundacionais para dados tabulares.

Métricas

Classificação

Para os datasets de classificação, o grupo deve reportar:

- Accuracy;
- Macro F1;
- Weighted F1.

Regressão

Para os datasets de regressão, o grupo deve reportar:

- MAE;
- RMSE;
- R^2.

Qualidade da Imputação

Como os valores ausentes foram injetados artificialmente, o grupo deve comparar os valores imputados com os valores originais.

Para atributos numéricos, reportar pelo menos:

- MAE de imputação;

- RMSE de imputação.

Para atributos categóricos, reportar:

- acurácia da imputação.

Essa avaliação deve ser feita apenas nas posições em que valores foram removidos artificialmente.

Repetições

Cada configuração experimental deve ser executada pelo menos **3 vezes**.

Uma configuração experimental é definida por:

$$\text{dataset} \times \text{mecanismo de missingness} \times \text{percentual de nulos} \times \text{método de imputação} \times \text{modelo preditivo}$$

O relatório deve apresentar média e desvio padrão das métricas.

Caso o custo computacional fique alto, o grupo pode reduzir a quantidade de modelos preditivos avaliados em todos os cenários, mas deve manter:

- os quatro datasets;
- os três mecanismos de missingness;
- os sete percentuais de nulos;
- pelo menos três sementes;
- todos os métodos de imputação escolhidos.

Qualquer redução deve ser explicada no relatório.

Resultados

O grupo deve produzir tabelas e arquivos de resultados que permitam identificar, para cada dataset:

- desempenho sem injeção artificial de nulos;
- desempenho com `dropna`;
- desempenho com cada método de imputação;
- efeito do percentual de nulos;
- efeito do mecanismo MCAR, MAR e MNAR;
- qualidade da imputação;
- melhor combinação de imputador e modelo preditivo.

As tabelas principais do relatório não precisam conter todas as combinações possíveis. O grupo pode colocar tabelas resumidas no relatório e deixar tabelas completas em arquivos `.csv` anexos.

Visualizações

O relatório deve conter visualizações escolhidas pelo próprio grupo. As figuras devem ser usadas para sustentar a interpretação dos resultados.

Cada figura deve vir acompanhada de um parágrafo explicando:

- qual comparação está sendo feita;
- qual padrão aparece nos resultados;
- qual explicação o grupo propõe para esse padrão.

As visualizações devem ser baseadas nos resultados obtidos pelo grupo. Figuras genéricas, sem relação direta com os experimentos, serão desconsideradas.

Sugestões de visualizações:

- curvas de desempenho por percentual de nulos;
- comparação entre MCAR, MAR e MNAR;
- heatmap com mecanismo de missingness versus método de imputação;
- comparação entre qualidade da imputação e desempenho preditivo;
- gráfico mostrando quando métodos robustos superam métodos simples;
- comparação entre modelo básico e modelo de estado da arte.

Relatório

O relatório deve ter de 5 a 8 páginas, e deve conter:

1. **Introdução**
   - problema estudado;
   - motivação para comparar imputação sob MCAR, MAR e MNAR;
   - resumo do protocolo experimental.
2. **Datasets**
   - tabela-resumo dos quatro datasets;
   - tipo de tarefa;
   - variável-alvo;
   - quantidade original de valores ausentes;
   - quantidade de dados após criação da versão completa.
3. **Métodos**
   - imputadores do `scikit-learn`;
   - métodos externos escolhidos;
   - modelo tabular adicional escolhido;
   - justificativa das escolhas.
4. **Protocolo Experimental**
   - uso do `Jenga`;
   - mecanismos MCAR, MAR e MNAR;
   - percentuais de nulos;
   - divisão treino/teste;
   - métricas usadas.
5. **Resultados**
   - tabelas resumidas;
   - visualizações;
   - comparação entre métodos.
6. **Discussão**
   - quando imputação simples foi suficiente;
   - quando métodos externos trouxeram ganho;
   - diferença entre MCAR, MAR e MNAR;
   - relação entre qualidade da imputação e desempenho preditivo;

- efeito do modelo tabular adicional.

7. **Ameaças à Validade**
   - limitações dos datasets;
   - limitações da injeção artificial de nulos;
   - custo computacional;
   - sensibilidade a hiperparâmetros;
   - limitações dos métodos externos usados.
8. **Conclusão**
   - principais achados;
   - melhor estratégia geral;
   - casos em que não houve ganho claro;
   - recomendações práticas baseadas nos resultados.

Perguntas que devem ser respondidas

O relatório deve responder, usando números concretos dos experimentos:

1. O desempenho cai de forma semelhante em MCAR, MAR e MNAR?
2. Quais datasets foram mais sensíveis ao aumento do percentual de nulos?
3. Métodos simples, como `SimpleImputer`, foram competitivos em algum cenário?
4. Em quais cenários `KNNImputer` ou `IterativeImputer` superaram os métodos simples?
5. Os métodos externos ao `scikit-learn` superaram os métodos tradicionais? Em quais datasets e mecanismos?
6. A melhor qualidade de imputação levou necessariamente ao melhor desempenho preditivo?
7. O modelo tabular adicional mudou as conclusões em relação aos modelos básicos?
8. O comportamento foi diferente entre classificação e regressão?
9. Houve algum resultado inesperado? Qual explicação o grupo propõe?

Respostas genéricas não serão consideradas suficientes. Cada resposta deve apontar para tabelas, figuras ou arquivos de resultados produzidos pelo grupo.

Reprodutibilidade

A entrega deve permitir que os experimentos sejam reproduzidos.

O grupo deve incluir um arquivo `README.md` contendo:

- versão do Python;
- sistema operacional usado;
- instruções de instalação;
- comando ou ordem de execução dos notebooks/scripts;
- eventuais limitações de execução;
- tempo aproximado de execução;
- indicação de quais resultados estão em quais arquivos.

O grupo também deve incluir um arquivo `requirements.txt` ou `environment.yml`.

Apresentação Individual

Cada aluno deverá explicar rapidamente um resultado específico do trabalho.

A explicação terá duração aproximada de **2 minutos por aluno**.

O aluno deve escolher um resultado real obtido pelo grupo, por exemplo:

- uma diferença entre MCAR, MAR e MNAR;
- um caso em que um método externo superou os métodos do `scikit-learn`;
- um caso em que um método sofisticado não trouxe ganho;
- uma diferença entre qualidade da imputação e desempenho preditivo;
- uma diferença entre os modelos básicos e o modelo tabular adicional;
- uma análise sobre o efeito do percentual de nulos.

A explicação deve deixar claro:

1. qual resultado está sendo explicado;

2. em qual dataset, mecanismo e percentual de nulos ele ocorreu;
3. qual tabela ou figura mostra esse resultado;
4. qual interpretação o aluno dá para esse comportamento.

Entregáveis

1. Notebook Jupyter (.ipynb)

O notebook deve estar executado e organizado. Ele deve conter o protocolo de injeção com `Jenga`, os métodos de imputação, os modelos e as avaliações.

2. Relatório (PDF)

O relatório deve apresentar o protocolo, tabelas, visualizações e discussão dos resultados.

3. Arquivos de resultados

O grupo deve entregar os arquivos `.csv` ou `.json` com os resultados completos.

4. README de reprodução

Arquivo `README.md` com instruções para reproduzir os experimentos.

5. Ambiente

Arquivo `requirements.txt` ou `environment.yml`.

Formato de entrega: Pasta compactada `.zip` nomeada `Grupo[X]_Imputacao_Mestrado.zip` contendo `relatorio.pdf`, `notebook.ipynb`, `README.md`, arquivo de ambiente e os arquivos de resultados.

Critérios de Avaliação

Critério	Peso
Protocolo experimental com `Jenga` Criação da versão completa dos datasets; injeção de valores ausentes apenas nos atributos de entrada; preservação da variável-alvo; execução dos quatro datasets; comparação dos mecanismos MCAR, MAR e MNAR; uso dos percentuais 1%, 5%, 10%, 15%, 20%, 25% e 30%.	20%
Métodos de imputação Implementação e comparação de `dropna`, `SimpleImputer`, `KNNImputer`, `IterativeImputer` e pelo menos um método externo ao `scikit-learn`. A comparação deve incluir desempenho preditivo e qualidade da imputação nas posições artificialmente removidas.	20%
Modelos preditivos Uso dos modelos básicos do notebook inicial e inclusão de pelo menos um modelo tabular adicional, como CatBoost, LightGBM, XGBoost, TabPFN ou outro modelo justificado pelo grupo.	20%
Qualidade das tabelas, visualizações e discussão Organização dos resultados; uso de tabelas e figuras baseadas nos experimentos; análise do impacto dos mecanismos de ausência, dos percentuais de nulos, dos métodos de imputação e dos modelos preditivos.	20%
Explicação oral individual Cada aluno deve explicar um resultado real do trabalho, indicando em qual dataset, mecanismo e percentual de nulos ele ocorreu, onde aparece no relatório, notebook ou arquivos de resultados, e qual interpretação faz desse resultado.	20%

Observações

O uso de IA generativa, como ChatGPT, Claude ou ferramentas similares, é permitido, mas deve ser declarado no final do relatório, especificando em quais partes foi utilizada.

Plágio entre grupos resultará em nota zero para todos os envolvidos.

O grupo deve entregar código executável e resultados reprodutíveis.

Relatórios com discussões genéricas, sem referência direta aos resultados obtidos pelo grupo, serão penalizados.

Caso o grupo não consiga executar algum método externo por limitação técnica, deve docu-

mentar a tentativa, o erro encontrado e a solução adotada. A simples omissão do método será penalizada.